

Dương Trung Hiếu

MSV: 25022846

CHỦ ĐỀ:

- **Tên đề tài:** Vấn đề Thiên kiến (Bias) và Công bằng (Fairness) trong các thuật toán Học máy: Nguyên nhân và Giải pháp.
- **Lý do:** Đây là một trong những chủ đề quan trọng nhất của AI có trách nhiệm (Responsible AI). Nó kết hợp cả tư duy toán học/kỹ thuật (cách xử lý thuật toán) lẫn tư duy xã hội học (tác động của AI đến con người).
- **Phạm vi tìm kiếm & Tính thách thức:** Chủ đề này không chỉ dừng ở lý thuyết bề mặt mà đào sâu vào lõi kỹ thuật (phân tích sự sai lệch của tập dữ liệu, hàm mục tiêu) và tác động đạo đức, xã hội học. Đây là một bài toán mở, đầy thách thức và là xu hướng cốt lõi của ngành AI hiện nay (Responsible AI).

I. BÁO CÁO

a) Các nguồn đã tham khảo:

- Cơ sở dữ liệu học thuật/Tạp chí (Mehrabi, Pessach, Bellamy)
- Sách chuyên khảo/Giáo trình (Barocas, Kearns, O'Neil)
- Nguồn mở Internet/Báo chí (Dastin, Google)
- Nguồn mở rộng 1: Kỷ yếu hội thảo quốc tế hàng đầu về AI (Buolamwini, Hardt, Mitchell)
- Nguồn mở rộng 2: Báo cáo chuẩn mực của Chính phủ (NIST)

b) Bảng tổng hợp thông tin và đánh giá:

STT	Tác giả & Cơ quan XB (Uy tín)	Phương pháp & Tính cập nhật	Phân tích Ưu điểm	Phân tích Nhược điểm	Xếp hạng
1	Mehrabi et al. (2021) Tạp chí <i>ACM Computing Surveys</i>	Tổng quan tài liệu (Survey) rất toàn diện. Cập nhật: 2021. Trích dẫn >4000.	Ưu: Bao quát toàn bộ định nghĩa, phân loại bias. Uy tín học thuật từ ACM cực cao.	Nhược: Chỉ mang tính tổng hợp lý thuyết, không đưa ra thuật toán mới đột phá.	Rất cao
2	Buolamwini & Gebru (2018) Hội thảo <i>FAT (PMLR)</i>	Thực nghiệm kiểm chứng trên AI thị giác. Cập nhật: 2018. Trích dẫn >3500.	Ưu: Minh chứng bằng dữ liệu thực tế (Gender Shades), tác động mạnh mẽ đến các Big Tech.	Nhược: Chủ yếu tập trung vào thị giác máy tính (Computer Vision), ít đề cập đến NLP.	Rất cao
3	Hardt et al. (2016) Hội thảo <i>NeurIPS</i>	Phân tích toán học, tối ưu hóa thuật toán. Cập nhật: 2016. Trích dẫn >3000.	Ưu: Đặt nền móng toán học vững chắc cho khái niệm "Equality of Opportunity" trong Học máy.	Nhược: Hơi cũ (2016) so với tốc độ phát triển AI, nặng về lý thuyết toán, khó đọc.	Rất cao
4	Pessach & Shmueli (2022) Tạp chí <i>Machine Learning</i>	Tổng hợp và so sánh hiệu suất thuật toán. Cập nhật: 2022.	Ưu: Cập nhật các kỹ thuật giảm thiểu bias mới nhất, có đối chiếu hiệu quả định lượng.	Nhược: Chỉ tập trung vào dữ liệu dạng bảng (tabular data), bỏ qua deep learning.	Cao

STT	Tác giả & Cơ quan XB (Uy tín)	Phương pháp & Tính cập nhật	Phân tích Ưu điểm	Phân tích Nhược điểm	Xếp hạng
5	Bellamy et al. (2019) Tạp chí <i>IBM Journal of Research</i>	Nghiên cứu ứng dụng và mã nguồn mở. Cập nhật: 2019.	Ưu: Cung cấp bộ công cụ thực tế (AI Fairness 360) để lập trình viên áp dụng ngay.	Nhược: Có sự thiên lệch nhất định vì PR cho sản phẩm mã nguồn mở của IBM.	Cao
6	Mitchell et al. (2019) Hội thảo <i>FAT (ACM)</i>	Đề xuất khung tiêu chuẩn đánh giá (Framework). Cập nhật: 2019.	Ưu: Sáng tạo ra "Model Cards" - hiện là tiêu chuẩn vàng minh bạch mô hình AI.	Nhược: Là đề xuất chuẩn mực định tính, khó đánh giá bằng công thức toán học.	Rất cao
7	Barocas et al. (2023) NXB <i>MIT Press</i>	Sách giáo trình chuyên sâu. Cập nhật: 2023.	Ưu: Tính học thuật cực cao, cấu trúc như một giáo trình đại học tiêu chuẩn.	Nhược: Phức tạp đối với người đọc không có nền tảng toán học hoặc thống kê.	Rất cao
8	Kearns & Roth (2019) NXB <i>Đại học Oxford</i>	Sách chuyên khảo về đạo đức AI. Cập nhật: 2019.	Ưu: Giải thích khái niệm thuật toán phức tạp bằng ngôn ngữ dễ hiểu, văn phong lôi cuốn.	Nhược: Thiếu các đoạn code hoặc ví dụ lập trình cụ thể cho sinh viên thực hành.	Cao

STT	Tác giả & Cơ quan XB (Uy tín)	Phương pháp & Tính cập nhật	Phân tích Ưu điểm	Phân tích Nhược điểm	Xếp hạng
9	O'Neil, C. (2016) NXB Crown	Sách nghiên cứu tình huống (Case studies). Cập nhật: 2016.	Ưu: Ví dụ cực kỳ sống động về tác hại xã hội của AI; góc nhìn thực tiễn.	Nhược: Tính hàn lâm học thuật không cao bằng các bài báo hội thảo/tạp chí.	Trung bình - Cao
10	NIST (2022) Viện Tiêu chuẩn Công nghệ Mỹ	Nghiên cứu quy chuẩn quốc gia. Cập nhật: 2022.	Ưu: Độ tin cậy tuyệt đối từ tổ chức chính phủ; là tài liệu định hướng pháp lý.	Nhược: Văn phong hành chính, khô khan, không đi sâu vào code kỹ thuật.	Rất cao
11	Google (2024) Website công ty - Nguồn Internet	Báo cáo thực hành nội bộ (Use cases). Cập nhật: 2024.	Ưu: Thể hiện cách các tập đoàn lớn nhất đang xử lý bias thực tế như thế nào.	Nhược: Không có bình duyệt độc lập, mang tính chất tuyên truyền cho doanh nghiệp.	Trung bình
12	Dastin, J. (2018) Báo Reuters - Nguồn Internet	Báo cáo điều tra / Tin tức. Cập nhật: 2018.	Ưu: Bằng chứng thực tế sắc bén (scandal tuyển dụng của Amazon) giúp mở bài báo cáo.	Nhược: Nguồn tin tức báo chí, hoàn toàn thiếu cấu trúc lý thuyết khoa học.	Trung bình

Barocas, S., Hardt, M. and Narayanan, A. (2023) *Fairness and Machine Learning: Limitations and Opportunities*. Cambridge: MIT Press.

Bellamy, R.K., Moindrot, K., Kato, S., et al. (2019) 'AI Fairness 360: An extensible toolkit for detecting and mitigating algorithmic bias', *IBM Journal of Research and Development*, 63(4/5), pp. 4-1.

Buolamwini, J. and Gebru, T. (2018) 'Gender shades: Intersectional accuracy disparities in commercial gender classification', *Proceedings of the 1st Conference on Fairness, Accountability and Transparency*, PMLR 81, pp. 77-91.

Dastin, J. (2018) 'Amazon scraps secret AI recruiting tool that showed bias against women', *Reuters*, 10 October. Available at: <https://www.reuters.com/article/us-amazon-com-jobs-automation-insight-idUSKCN1MK08G> (Accessed: 16 March 2026).

Google (2024) *Responsible AI Practices*. Available at: <https://ai.google/responsibility/principles/> (Accessed: 16 March 2026).

Hardt, M., Price, E. and Srebro, N. (2016) 'Equality of opportunity in supervised learning', *Advances in Neural Information Processing Systems*, 29.

Kearns, M. and Roth, A. (2019) *The ethical algorithm: The science of socially aware algorithm design*. New York: Oxford University Press.

Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K. and Galstyan, A. (2021) 'A survey on bias and fairness in machine learning', *ACM Computing Surveys (CSUR)*, 54(6), pp. 1-35.

Mitchell, M., Wu, S., Zaldivar, A., et al. (2019) 'Model cards for model reporting', *Proceedings of the Conference on Fairness, Accountability, and Transparency*, pp. 220-229.

NIST (2022) *Towards a Standard for Identifying and Managing Bias in Artificial Intelligence*. Special Publication 1270. Gaithersburg: National Institute of Standards and Technology.

O'Neil, C. (2016) *Weapons of math destruction: How big data increases inequality and threatens democracy*. New York: Crown.

Pessach, D. and Shmueli, E. (2022) 'Algorithmic fairness', *Machine Learning*, 111(5), pp. 1737-1801.